

Stitching de imágenes mediante homografías

Trabajo Práctico 1 – I308 Visión Artificial

Justina Decunto

Federico Bignone

Julia Pantin

jdecunto@udesa.edu.ar

fbignone@udesa.edu.ar

jpantin@udesa.edu.ar

Septiembre de 2026

1. Introducción

El objetivo del trabajo es construir una imagen panorámica sin costuras visibles a partir de tres fotografías parcialmente superpuestas. Para ello se implementó un pipeline que detecta características locales, establece correspondencias, estima transformaciones proyectivas, lleva las imágenes a un sistema de referencia común y finalmente las combina mediante *blending*. La imagen central se utilizó como ancla y las imágenes laterales se transformaron hacia su sistema de coordenadas.

Una homografía es una transformación proyectiva entre puntos de dos imágenes. Para un punto $\mathbf{x} = (x, y, 1)^T$ y su correspondencia $\mathbf{x}'$, la relación se expresa como

$$\mathbf{x}' \sim H\mathbf{x}, \quad H \in R^{3 \times 3}, \quad (1)$$

donde la igualdad es a menos de un factor de escala. La matriz H posee ocho grados de libertad, por lo que se requieren al menos cuatro correspondencias no degeneradas.

El uso de una homografía para relacionar dos vistas se deduce del modelo de cámara pinhole, según el cual un punto del mundo se proyecta como $\mathbf{u} \sim K[R | \mathbf{t}] \mathbf{X}_w$, con K la matriz intrínseca y $[R | \mathbf{t}]$ los parámetros extrínsecos. De allí surgen los dos casos en que dos vistas se relacionan exactamente por una matriz de 3×3 . Si la escena es plana, puede elegirse el sistema del mundo con el plano en $Z = 0$: la tercera columna de R queda multiplicada por cero, la matriz de proyección de 3×4 se reduce a una de 3×3 y esa matriz es la homografía. Si la cámara solo rota alrededor de su centro óptico, entonces $\mathbf{t} = \mathbf{0}$ y la relación entre ambas vistas es $\mathbf{u}' \sim K R K^{-1} \mathbf{u}$, que tampoco depende de la profundidad de los puntos.

Fuera de estos dos casos el modelo deja de ser exacto: si existen objetos a distintas profundidades y la cámara se traslada aparece paralaje, los objetos cercanos se desplazan más que los lejanos entre una toma y la otra, cada plano requiere una transformación distinta y no pueden alinearse simultáneamente con una sola H .

Los tres conjuntos utilizados se ordenan según cuán bien cumplen estas hipótesis. El conjunto *Cuadro* es el caso más desfavorable: la escena está a aproximadamente un metro y contiene al menos tres planos, la pared con el cuadro, la caja apoyada sobre la mesa y la mesa misma, con diferencias de profundidad que representan una fracción apreciable de la distancia a la cámara. El cuadro y la pared forman el plano de mayor extensión y dominan la estimación, de modo que el cuadro se alinea correctamente aunque la caja aparezca duplicada. En el conjunto *UdeSA* provisto los edificios están a decenas de metros: las diferencias de profundidad relativas son mucho menores y la escena se comporta aproximadamente como un plano lejano, por lo que la homografía resulta una buena aproximación aun cuando el fotógrafo no haya rotado de manera perfecta. El conjunto propio es el más favorable, ya que además de ser una escena lejana las fotografías se tomaron girando sobre el propio eje, lo cual aproxima la condición de rotación pura.

2. Método

2.1. Detección, descripción y ANMS

Se utilizaron características SIFT, invariantes a traslación, rotación y escala por construcción y parcialmente invariantes a cambios de iluminación. Cada keypoint queda descrito por un vector de 128 dimensiones que se compara mediante norma euclídea. Las imágenes provistas se redujeron al 50 % para disminuir el costo de cómputo, mientras que las fotografías propias se conservaron en su resolución de 1024×768 píxeles.

La detección inicial produce muchos puntos concentrados en regiones de alta textura, lo cual perjudica la estimación de la homografía en el resto de la imagen. Para distribuirlos mejor se implementó *Adaptive Non-Maximal Suppression*

(ANMS). A cada keypoint k_i , con respuesta r_i y posición (x_i, y_i) , se le asigna un radio de supresión

$$R_i = \min_{j: r_j > r_i} \|(x_i, y_i) - (x_j, y_j)\|, \quad (2)$$

es decir, la distancia al keypoint más cercano *entre aquellos cuya respuesta es mayor que la suya*. Un punto que es el más fuerte de su entorno recibe un radio grande y uno que tiene un vecino más fuerte al lado recibe un radio pequeño; se ordenan por R_i y se conservan los primeros N , lo que selecciona puntos fuertes y a la vez separados entre sí. Respecto del pseudocódigo del enunciado se omitió el paso de restringirse a los máximos locales de una vecindad fija, porque los keypoints de SIFT ya son máximos locales de la respuesta de diferencia de gaussianas en el espacio de escala, y se anidó la comparación de distancias dentro de la comparación de respuestas, que en el pseudocódigo quedan al mismo nivel. También se eliminaron las detecciones repetidas en la misma coordenada, generadas por las múltiples orientaciones asignadas por SIFT, que representan alrededor del 18 % del total y que, conservadas, reciben radio nulo y se pierden.

El valor de N se eligió en proporción a los keypoints disponibles en cada conjunto. En *Cuadro* SIFT detecta unos 1500 puntos por imagen, de los cuales alrededor de 1300 quedan tras eliminar duplicados, y se usó $N = 500$. En *UdeSA* provisto la detección arroja entre 3800 y 10000 puntos, de modo que el mismo valor descartaría más del 90 % del material y dejaría el par derecho con muy pocas correspondencias; allí se usó $N = 1500$. En el conjunto propio, de menor resolución, se volvió a usar $N = 500$.



(a) Características SIFT originales.

(b) Características seleccionadas mediante ANMS.

Figura 1: El ANMS reduce la concentración de puntos sobre los contornos de alto contraste y aporta detecciones en la mesa y el piso. La pared permanece sin puntos porque es una superficie lisa: el método redistribuye los puntos existentes, no genera nuevos.

2.2. Asociación de características

Los descriptores SIFT se compararon utilizando distancia euclídea. Se evaluaron dos criterios de asociación:

- **Verificación cruzada:** exige que la asociación entre dos características sea mutua.
- **Prueba de Lowe:** descarta asociaciones ambiguas comparando las distancias de los dos vecinos más cercanos.

Se utilizó un umbral de Lowe de 0.75. Sobre el conjunto *Cuadro*, la verificación cruzada por sí sola deja 149 y 148 correspondencias para los pares izquierdo y derecho, con numerosas líneas cruzadas que evidencian asociaciones incorrectas; la prueba de Lowe resulta bastante más selectiva y deja 73 y 50. Se tomó finalmente la intersección de

ambos criterios, que reduce el conjunto a 54 y 44 correspondencias: es la opción más conservadora y deja menos trabajo de descarte a RANSAC.



(a) Imagen izquierda contra el ancla.



(b) Imagen derecha contra el ancla.

Figura 2: Correspondencias que superan simultáneamente Lowe y cross-check.

2.3. Estimación manual de la homografía

Se seleccionaron manualmente cuatro correspondencias para cada par del conjunto *Cuadro* y se implementó DLT (*Direct Linear Transformation*) sin utilizar la estimación de homografías de OpenCV. Partiendo de la Ecuación (1) y eliminando el factor de escala al dividir por la tercera componente, cada correspondencia $(x, y) \leftrightarrow (x', y')$ aporta dos ecuaciones lineales en las incógnitas de H :

$$\begin{bmatrix} -x & -y & -1 & 0 & 0 & 0 & xx' & yx' & x' \\ 0 & 0 & 0 & -x & -y & -1 & xy' & yy' & y' \end{bmatrix} \mathbf{h} = \mathbf{0}, \quad (3)$$

con $\mathbf{h}$ el vector de los nueve coeficientes de H . Apilando las filas de todas las correspondencias se obtiene $A\mathbf{h} = \mathbf{0}$. Con exactamente cuatro pares, fijar $h_{33} = 1$ deja un sistema de ocho ecuaciones con ocho incógnitas y solución única. Con más de cuatro el sistema queda sobredeterminado y se resuelve por cuadrados mínimos: se minimiza $\|A\mathbf{h}\|$ sujeto a $\|\mathbf{h}\| = 1$ para descartar la solución trivial, y la solución es el vector singular asociado al menor valor singular de A , esto es la última columna de V en la descomposición $A = U\Sigma V^T$. La primera variante se utiliza dentro de RANSAC y la segunda para el ajuste final sobre los inliers.

Sobre la elección de los cuatro pares, el criterio más importante es que los puntos sean *coplanares*, es decir que pertenezcan a un mismo plano físico de la escena: una homografía puede alinear un plano por vez, de modo que si dos puntos se toman sobre la pared y dos sobre la caja, la transformación resultante no alinea correctamente ninguno de los dos. Deben además ser visibles en ambas imágenes, corresponder a detalles únicos y localizables con precisión y no a texturas repetidas, estar repartidos por la imagen en lugar de agrupados en una región, y no incluir tres colineales, porque en ese caso la matriz A se vuelve singular o queda mal condicionada y la solución pierde sentido.

El error sobre los cuatro puntos manuales fue del orden de 10^{-13} píxeles. Este valor no demuestra por sí solo la calidad de la transformación: cuatro correspondencias no degeneradas determinan un sistema exacto incluso si fueron seleccionadas incorrectamente. Por este motivo, la homografía también se evaluó visualmente mediante la superposición de la imagen transformada y el ancla.



Figura 3: Correspondencias seleccionadas manualmente. En la imagen derecha de cada par, las cruces rojas marcan los puntos elegidos sobre el ancla y las verdes los obtenidos al proyectar los de la otra imagen con la homografía estimada.

2.4. RANSAC

Para la estimación automática de las homografías se implementó RANSAC, también sin utilizar la implementación de OpenCV. En cada una de $T = 2000$ iteraciones se seleccionaron cuatro correspondencias al azar, se calculó una homografía mediante DLT y se midió la distancia de reproyección de todas las correspondencias. Se consideraron inliers los puntos con un error menor que $t = 5$ píxeles y, finalmente, la homografía se recalculó mediante SVD utilizando todos los inliers del mejor conjunto de consenso.

El umbral se fijó a partir de un barrido: con $t = 3$ el error baja pero se pierde alrededor de un cuarto de los inliers, y con $t = 8$ el error del par derecho de *Cuadro* pasa de 2.11 a 4.87 píxeles, lo que indica que ya están ingresando correspondencias incorrectas al ajuste. La cantidad de iteraciones se justifica con la expresión del número mínimo necesario para que, con probabilidad p , al menos una muestra esté libre de outliers,

$$T = \frac{\log(1 - p)}{\log(1 - (1 - e)^s)}, \quad (4)$$

donde $s = 4$ es la cantidad mínima de puntos para determinar el modelo y e la proporción de outliers. Para el peor caso observado, $e \approx 0.7$, y exigiendo $p = 0.99$, la expresión da aproximadamente 570 iteraciones, de modo que el valor utilizado deja un margen holgado. El error de reproyección reportado, calculado sobre los inliers, es

$$e_{\text{RMS}} = \sqrt{\frac{1}{N} \sum_{i=1}^N \|\pi(H\mathbf{x}_i) - \mathbf{x}'_i\|_2^2}, \quad (5)$$

donde π representa la conversión de coordenadas homogéneas a coordenadas cartesianas.

2.5. Cálculo del canvas

Para evitar que las imágenes transformadas quedaran cortadas, se transformaron las cuatro esquinas de cada imagen hacia el sistema de coordenadas del ancla. Si $\mathcal{C}$ es el conjunto de todas las esquinas transformadas, los límites del canvas se obtienen tomando mínimos y máximos componente a componente sobre $\mathcal{C}$,

$$x_{\min} = \lfloor \min_{\mathbf{p} \in \mathcal{C}} p_x \rfloor, \quad y_{\min} = \lfloor \min_{\mathbf{p} \in \mathcal{C}} p_y \rfloor, \quad x_{\max} = \lceil \max_{\mathbf{p} \in \mathcal{C}} p_x \rceil, \quad y_{\max} = \lceil \max_{\mathbf{p} \in \mathcal{C}} p_y \rceil, \quad (6)$$

que definen el rectángulo mínimo que contiene a las tres imágenes transformadas. Cuando los mínimos son negativos, todas las homografías se componen a izquierda con una matriz de traslación

$$T = \begin{bmatrix} 1 & 0 & -x_{\min} \\ 0 & 1 & -y_{\min} \\ 0 & 0 & 1 \end{bmatrix}, \quad H_k^{\text{final}} = T H_k, \quad (7)$$

de manera que todo el contenido cae en coordenadas positivas. El tamaño final del canvas resulta $(x_{\max} - x_{\min}) \times (y_{\max} - y_{\min})$ y ninguna de las imágenes transformadas queda fuera de la región resultante. Para el conjunto *Cuadro* se obtuvo una traslación de (925, 323) píxeles y un canvas de 3137×3243 .

2.6. Stitching y blending


El pegado directo de las imágenes evidencia cambios de exposición y costuras. Para suavizarlos se construyó, para cada imagen transformada, una máscara W_i basada en la transformada de distancia de su región válida, máxima en el centro de la imagen y nula en sus bordes. Cada canal de color se combinó por separado mediante

$$I(\mathbf{x}) = \frac{\sum_i W_i(\mathbf{x}) I_i(\mathbf{x})}{\sum_i W_i(\mathbf{x})}. \quad (8)$$

Utilizando directamente la transformada de distancia normalizada como peso, la franja en la que ambas imágenes contribuyen en proporciones parecidas resulta ancha. Eso corrige bien las diferencias de exposición, pero en las regiones con paralaje promedia dos versiones desalineadas del mismo objeto y produce fantasmas. Por ese motivo se elevó el peso a una potencia,

$$W_i = \left(\frac{d_i}{\max d_i} \right)^\gamma, \quad \gamma = 6, \quad (9)$$

donde d_i es la transformada de distancia de la región válida de la imagen i . El exponente no modifica el método, solo concentra el peso cerca del centro de cada imagen y angosta la franja de mezcla, con lo cual en casi toda la zona de solapamiento predomina la imagen cuyo centro está más cerca. El costo es que la corrección de exposición actúa sobre una franja más angosta; en estos conjuntos la elección conviene, porque las exposiciones son parecidas y el problema dominante es el paralaje.



(a) Stitching sin mezcla.

(b) Mezcla ponderada con $\gamma = 1$ y con $\gamma = 6$.

Figura 4: El pegado directo deja costuras rectas producidas por las diferencias de exposición. La mezcla ponderada las elimina, pero con $\gamma = 1$ la caja aparece semitransparente porque el promedio muestra a la vez sus dos posiciones; con el exponente la transición se concentra y la caja se ve nítida. En ningún caso se corrige el paralaje.

3. Resultados

La Tabla 1 resume las correspondencias aceptadas por RANSAC y los errores de reproyección de las homografías finales.

Conjunto	Par hacia el ancla	Inliers	Proporción	Error RMS [px]
Cuadro	izquierda-centro	22/54	40.7 %	2.27
Cuadro	derecha-centro	14/44	31.8 %	2.11
UdeSA provisto	izquierda-centro	156/181	86.2 %	1.19
UdeSA provisto	derecha-centro	33/49	67.3 %	2.14
UdeSA propio	izquierda-centro	101/104	97.1 %	1.44
UdeSA propio	derecha-centro	67/69	97.1 %	2.20

Tabla 1: Resultados de RANSAC para las homografías finales.

La proporción de inliers reproduce el ordenamiento anticipado en la introducción. Las fotografías propias alcanzan aproximadamente un 97 % en ambos pares, consistente con una escena lejana fotografiada girando sobre el eje, y

el conjunto *UdeSA* provisto queda en valores intermedios. El conjunto *Cuadro* obtiene la proporción más baja, en torno al 35 %, y no por deficiencias del método: muchas de las correspondencias válidas pertenecen a la caja y a la mesa, que están en planos distintos del de la pared, y por lo tanto no pueden ser consistentes con la homografía que RANSAC selecciona. El algoritmo se queda con el plano de mayor consenso y descarta el resto, que es exactamente el comportamiento esperado.

Girar el cuerpo no garantiza una rotación pura alrededor del centro óptico: al sostener el teléfono la cámara describe un pequeño arco y puede cambiar su inclinación. Aun así, el alto consenso de RANSAC permitió alinear correctamente la estructura principal de los edificios.

El canvas completo conserva toda la información transformada y, por lo tanto, contiene regiones negras debido a que la unión de los cuadriláteros proyectados no es rectangular. Esas regiones no son bordes sobrantes en el sentido del enunciado: el rectángulo ya es el mínimo que contiene a las tres imágenes y reducirlo implicaría recortar contenido válido. Se generó adicionalmente un recorte para la presentación visual, conservando el resultado sin recortar como evidencia del cálculo geométrico del canvas.



Figura 5: Panorámica obtenida con el conjunto UdeSA provisto.



Figura 6: Resultado final sobre las fotografías propias, recortado para su presentación.

4. Conclusiones

El pipeline implementado permitió construir panorámicas a partir de los conjuntos provistos y de las fotografías propias. ANMS mejoró la distribución espacial de las características, la combinación de Lowe y cross-check redujo las asociaciones ambiguas, RANSAC permitió estimar homografías robustas frente a outliers, el cálculo de las esquinas transformadas evitó cortar contenido y el blending redujo las costuras causadas por diferencias de exposición.

Las principales limitaciones observadas provienen de las hipótesis geométricas del modelo y no de la implementación. Una única homografía no puede compensar simultáneamente objetos pertenecientes a planos diferentes cuando existe traslación de la cámara. En esas regiones, el blending suaviza las transiciones de color pero no corrige la desalineación, por lo que pueden persistir transparencias, duplicaciones y *ghosting*. La comparación entre los tres conjuntos lo muestra: la calidad del resultado depende de cuánto se aproxima la toma a una escena plana o a una rotación pura, más que de los parámetros del pipeline.